Τμήμα Μηχανικών Η/Υ & Πληροφορικής

Πανεπιστήμιο Πατρών

Ανάκτηση Πληροφορίας

Εργαστηριακή Άσκηση

Χειμερινό Εξάμηνο 2025

Διδάσκων: Χ. Μακρής

Διδακτορικοι Επιβλεποντες: Καλογερόπουλος Νικήτας-Ρήγας/Μπομπότας Αγοράκης,

Στόχος

Στα πλαίσια της παρούσας εργασίας ζητείται η μελέτη, η υλοποίηση και η σύγκριση μηχανών αναζήτησης. Θα κληθείτε να επεξεργαστείτε μία συλλογή να εφαρμόσετε μοντέλα ανάκτησης πληροφορίας σε αυτή με δεδομένα ερωτήματα και λίστες σχετικών κειμένων. Με βάση, λοιπόν, τα δεδομένα αυτά θα εφαρμόσετε τις κατάλληλες μετρικές αξιολόγησης και θα καταγράψετε τις παρατηρήσεις σας. Για τα **μοντέλα** και τις **μετρικες** που θα υλοποιήσετε **δε πρέπει** να χρησιμοποιήσετε έτοιμες λύσεις, αν και μπορούν να χρησιμοποιηθούν για επαλήθευση.

Η συλλογή

Η συλλογή που σας έχει δοθεί είναι η Cystic Fibrosis (C.F)[1,2] και περιλαμβάνει 1239 κείμενα και 100 ερωτήματα. Απο τα 100 ερωτήματα αυτά σας έχει δοθεί ένα υποσύνολο αυτων (20 ερωτήματα) που μπορείτε να χρησιμοποιήσετε. Κάθε αρχείο έχει σαν όνομα το ID του κειμένου και σαν περιεχόμενο τον τίτλο του και το κείμενο. Τα ερωτήματα περιλαμβάνουν μία λίστα κειμένων που θεωρούνται σχετικά με το ερώτημα καθως και ο βαθμός σχετικότητας τους απο ειδικούς, που δύναται να εφαρμοστεί σε κατάλληλες μετρικές.

Ερωτήματα

[1] https://people.ischool.berkeley.edu/~hearst/irbook/cfc.html

[2] Shaw, W.M. & Wood, J.B. & Wood, R.E. & Tibbo, H.R. The Cystic Fibrosis Database: Content and Research Opportunities. LISR 13, pp. 347-3GG, 1991.

Ερώτημα 1 - Ανάγνωση και Επεξεργασία της Συλλογής (Μονάδες 1)

Στο ερώτημα αυτό θα πρέπει να διαπεράσετε τη συλλογή ώστε να παραχθεί **το κατάλληλο ανεστραμμένο ευρετήριο** που θα περιλαμβάνει την πληροφορία που θα χρειαστούν **τα μοντέλα στα επόμενα ερωτήματα.** Στο σημείο αυτό μπορείτε να κάνετε και οποιαδήποτε μορφή προεπεξεργασίας εσείς κρίνετε απαραίτητη. Στη συλλογή θα παρατηρήσετε ότι υπάρχουν κείμενα τα οποία **απουσιάζουν**. Θα πρέπει να διαχειριστείτε το πρόβλημα αυτό ώστε να **μην υπάρχει** κάποια αναντιστοιχία μεταξύ των id των κειμένων και αυτών που βρίσκονται στις λίστες σχετικών ερωτημάτων.

Στην αναφορά σας, εκτος άλλων, θα πρέπει να συμπεριλάβετε:

- *Τη δομή κάθε ευρετηρίου.*
- *Αιτιολόγηση της δομής που επιλέχθηκε.*
- *Τεχνικές προεπεξεργασίας και αιτιολόγηση τους, αν εφαρμόστηκαν.*
- *Τον τρόπο διαχείρισης των κειμένων που απουσιάζουν.*
- *Αν θέλετε να συμπεριλάβετε κώδικα στην αναφορά σας διαμορφώστε μία ενότητα με τίτλο "Παράρτημα" και παρουσίαστε τον σε εκείνο το σημείο μαζί με μία σύντομη περιγραφή.*

Ερώτημα 2 - Υλοποίηση Μοντέλου Διανυσματικού Χώρου (Vector Space Model - VSM) (Μονάδες 3)

Στο ερώτημα αυτό, θα υλοποιήσετε το μοντέλο ανάκτησης πληροφορίας διανυσματικού χώρου[3],[4] (Vector Space Model - VSM) χρησιμοποιώντας ως είσοδο το ευρετήριο που δημιουργήσατε στο πρώτο ερώτημα. Στόχος είναι η αξιολόγηση της ομοιότητας μεταξύ ερωτήματος και των εγγράφων, βασιζόμενοι στη συσχέτιση των όρων. Για τη στάθμιση των όρων, να εφαρμόσετε δύο διαφορετικά τυπολόγια, εκ των οποίων το πρώτο θα βασίζεται στο κλασικό tf–idf, ενώ το δεύτερο μπορεί να είναι κάποιο εναλλακτικό, όπως αυτό περιγράφεται στη δημοσίευση "Term-weighting approaches in automatic text retrieval". Στη συνέχεια, να υπολογίσετε την ομοιότητα μεταξύ των ερωτημάτων και των εγγράφων και να παράξετε μία κατάταξη.

Βασικά σημεία που πρέπει να περιλαμβάνει η υλοποίησή σας:

- Αναπαράσταση εγγράφων και ερωτημάτων ως **διανύσματα**: Κάθε έγγραφο και το ερώτημα θα πρέπει να αναπαριστώνται ως διανύσματα με βάση τους όρους που περιέχουν.
- Συντελεστές βαρύτητας όρων: Υπολογισμός των συντελεστών βαρύτητας των όρων, χρησιμοποιώντας τεχνικές όπως το **TF-IDF** (Term Frequency - Inverse Document Frequency).

---

[3] *Gerard Salton, Christopher Buckley,Term-weighting approaches in automatic text retrieval, Information Processing & Management, Volume 24, Issue 5, 1988,Pages 513-523,ISSN 0306-4573,https://doi.org/10.1016/0306-4573(88)90021-0.*

[4] *G. Salton, A. Wong, and C. S. Yang. 1975. A vector space model for automatic indexing. Commun. ACM 18, 11 (Nov. 1975), 613–620. https://doi.org/10.1145/361219.361220*

- Υπολογισμός συσχέτισης: Εφαρμογή του **συνημίτονου της γωνίας (cosine similarit**y) για την εύρεση της ομοιότητας μεταξύ του ερωτήματος και των εγγράφων.
- Ταξινόμηση εγγράφων: Ταξινόμηση των εγγράφων **με βάση τη βαθμολογία ομοιότητας** και επιστροφή των πιο σχετικών εγγράφων.

Ερώτημα 3 -Υλοποίηση Μετρικών Αξιολόγησης Ανάκτησης Πληροφορίας (Μονάδες 1)

Να υλοποιήσετε τις συναρτήσεις υπολογισμού των βασικών μετρικών αξιολόγησης ενός συστήματος ανάκτησης πληροφορίας. Συγκεκριμένα, να υλοποιηθούν οι μετρικές Ακρίβεια (Precision), Ανάκληση (Recall), F1-score, καθώς και Precision@k για διαφορετικές τιμές του k. Επιπλέον, να υλοποιήθει συνάρτηση που παράγει το διάγραμμα Ανάκλησης–Ακρίβειας (Precision–Recall Curve), χωρίς να απαιτείται υπολογισμός ή σύγκριση αποτελεσμάτων σε αυτό το στάδιο, αφου θα γίνει σε επόμενο ερώτημα.

Ερώτημα 4 -Συγκρίσεις (Μονάδες 3)

Να υλοποιήσετε τη διαδικασία παραμετροποίησης του μετασχηματιστή TfidfVectorizer της βιβλιοθήκης scikit-learn, με στόχο τη βελτίωση της απόδοσης του συστήματος ανάκτησης που αναπτύξατε στα προηγούμενα ερωτήματα. Η παραμετροποίηση μπορεί να πραγματοποιηθεί είτε με χρήση της κλάσης GridSearchCV από το υποπακέτο sklearn.model_selection, είτε με εναλλακτικό τρόπο (π.χ. μέσω χειροκίνητης δοκιμής διαφορετικών συνδυασμών υπερπαραμέτρων). Θα πρέπει να εξεταστούν περισσότερες από 30 επιλογές

Να εξετάσετε διαφορετικές τιμές για βασικές υπερπαραμέτρους του TfidfVectorizer, όπως:

- το εύρος των n-grams (ngram_range),
- η εφαρμογή λογαριθμικής στάθμισης (sublinear_tf=True),
- τα όρια εμφάνισης όρων (min_df, max_df),
- και το είδος κανονικοποίησης (norm: ‘l1’, ‘l2’ ή None).

Η αξιολόγηση των διαφορετικών παραμέτρων να βασιστεί στις μετρικές του Ερωτήματος 3 (Precision, Recall, F1-score, Precision@k), ώστε να επιλεγεί ο συνδυασμός παραμέτρων που προσφέρει τη βέλτιστη απόδοση. Να επιλέξετε τις κατάλληλες μετρικές που θα διευκολύνουν την σύγκριση των παραμετρων.

Αφού εντοπιστεί το καλύτερο μοντέλο, να αιτιολογήσετε την επιλογή του, εξηγώντας ποιοι παράγοντες συνέβαλαν στη βελτίωση της ανάκτησης. Τέλος, να πραγματοποιήσετε σύγκριση μεταξύ του παραμετροποιημένου μοντέλου TF–IDF και των μοντέλων που υλοποιηθηκαν στο Ερώτημα 2 με όλες τις

μετρικές. Τέλος, να χρονομετρήσετε την διαδικασία ανάκτησης και δεικτοδότησης των μοντέλων και να σχολιάσετε τις παρατηρήσεις σας.

Ερώτημα 5 - Clustering με TF–IDF και προεκπαιδευμένες ενσωματώσεις (Μονάδες 2)

Στο παρόν ερώτημα θα υλοποιήσετε διαδικασίες συσταδοποίησης (clustering) για τη συλλογή εγγράφων, χρησιμοποιώντας δύο διαφορετικές αναπαραστάσεις: (α) το μοντέλο TF–IDF που προέκυψε από το Ερώτημα 4, και (β) πυκνές ενσωματώσεις κειμένου (text embeddings) που θα εξαχθούν από ένα προεκπαιδευμένο μοντέλο του **Hugging Face**. Στόχος είναι να διερευνηθεί πώς διαφορετικοί τρόποι αναπαράστασης επηρεάζουν την ομαδοποίηση εγγράφων με βάση τη θεματική ή σημασιολογική τους συνάφεια.
Για την πρώτη αναπαράσταση (TF–IDF), να χρησιμοποιήσετε τον παραμετροποιημένο μετασχηματιστή TfidfVectorizer που υλοποιήσατε στο Ερώτημα 4, ώστε κάθε έγγραφο να αναπαρίσταται ως αραιό διάνυσμα όρων. Για τη δεύτερη αναπαράσταση, να χρησιμοποιήσετε προεκπαιδευμένο μοντέλο ενσωματώσεων από τη βιβλιοθήκη sentence-transformers ή transformers του Hugging Face, με σκοπό την παραγωγή πυκνών διανυσματικών αναπαραστάσεων που αποτυπώνουν τη σημασιολογική πληροφορία των εγγράφων. Ενδεικτικά μπορούν να χρησιμοποιηθεί το μοντέλο sentence-transformers/all-MiniLM-L6-v2 (για αγγλικά)
Στη συνέχεια, να εφαρμόσετε αλγόριθμο συσταδοποίησης της βιβλιοθήκης scikit-learn, όπως τον KMeans ή τον AgglomerativeClustering, με κατάλληλη επιλογή του αριθμού συστάδων (k). Ο αριθμός k μπορεί να επιλεγεί εμπειρικά ή με τη βοήθεια μετρικών και αλγορίθμων όπως Silhouette Score και η μέθοδος του αγκώνα (Elbow method), ώστε να προσδιοριστεί ο αριθμός που οδηγεί στις πιο συμπαγείς και διακριτές συστάδες. Να οπτικοποιήσετε τα αποτελέσματα σας σε χώρο 2 διαστάσεων χρησιμοποιώντας PCA.

Παραδοτέα

1. Τα αρχεία κώδικα που υλοποιούν τα ζητούμενα της εκφώνησης.
2. Μια αναφορά σε μορφή pdf η οποία θα πρέπει να περιέχει τα ακόλουθα (επισυνάπτεται δείγμα):
   a. Τα στοιχεία (**ΑΜ, *ονοματεπώνυμο* και email**) του φοιτητή ή των φοιτητών που παραδίδουν την άσκηση.
   b. Αναλυτική καταγραφή του περιβάλλοντος υλοποίησης (γλώσσα προγραμματισμού, βιβλιοθήκες λογισμικού κτλ.) καθώς και τα βήματα που απαιτούνται για την εγκατάστασή του.
   c. Περιγραφή της διαδικασία υλοποίησης.
   d. Σχολιασμό των τελικών αποτελεσμάτων.

Διαδικαστικά

1. Επιλέγετε ή την υλοποιητική ή την θεωρητική εργασία.
2. Η άσκηση μπορεί να υλοποιηθεί είτε **ατομικά** είτε σε **ομάδες των δύο**.
3. Ως **ημερομηνία υποβολής** ορίζεται η **ημερομηνία τρεις ημέρες πριν την γραπτή εξέταση** του μαθήματος στις **23:59**.
4. Η άσκηση θα εξεταστεί προφορικά σε ημερομηνία μεταγενέστερη της ανακοίνωσης του προγράμματος της εξεταστικής. Κατα την εξεταση καλείστε να αιτιολογήσετε οτιδήποτε έχετε γράψει στην αναφορά σας, αλλά και στον κωδιΙ κά σας. ***Σε περίπτωση αδυναμίας επαρκούς τεκμηρίωσης, θα αφαιρούνται οι μονάδες που αντιστοιχούν στο εκάστοτε ερώτημα***.
5. Η αναφορά σας βαθμολογείται ως προς την πληρότητα με **1 μονάδα**.
6. Η υποβολή της άσκησης πρέπει να γίνει μέσω του eclass του μαθήματος. Τα παραδοτέα της άσκησης θα πρέπει να περιέχονται σε ένα συνημμένο αρχείο με όνομα της μορφής **ir2025_AM1_AM2.zip**
7. Η άσκηση μπορεί να αποσταλεί πολλές φορές αλλά θα βαθμολογηθεί μόνο η τελευταία της υποβολή.
8. Τις σχετικές με την υλοποιητική εργασία απορίες σας μπορείτε να τις αποστείλετε μέσω email στη διεύθυνση kalogeropo@ceid.upatras.gr (και κοινοποίηση σε makri@ceid.upatras.gr , mpompotas@ceid.upatras.gr)